




ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

Nhóm chuyên môn Trí tuệ nhân tạo

NHẬP MÔN TRÍ TUỆ NHÂN TẠO

Một số vấn đề cốt lõi với K-láng giềng gần



Các vấn đề cốt lõi của thuật toán K láng giềng

MỤC TIÊU



Sau bài học này, người học có thể:

Nắm được các vấn đề cốt lõi của thuật toán K láng giềng

1. Các vấn đề cốt lõi của thuật toán K láng giềng

1. CÁC VẤN ĐỀ CỐT LÕI CỦA THUẬT TOÁN K LÁNG GIỀNG



- Hàm khoảng cách
 - Mỗi hàm sẽ tương ứng với một cách nhìn về dữ liệu.
 - Vô hạn hàm!!!
 - Chọn hàm nào?

1. CÁC VẤN ĐỀ CỐT LÕI CỦA THUẬT TOÁN K LÁNG GIỀNG



- Hàm tính khoảng cách d
 - Đóng vai trò rất quan trọng trong phương pháp học dựa trên các láng giềng gần nhất
 - Thường được xác định trước, và không thay đổi trong suốt quá trình học và phân loại/dự đoán
- Lựa chọn hàm khoảng cách d
 - *Các hàm khoảng cách hình học*: Dành cho các bài toán có các thuộc tính đầu vào là kiểu số thực ($x_i \in \mathbb{R}$)
 - *Hàm khoảng cách Hamming*: Dành cho các bài toán có các thuộc tính đầu vào là kiểu nhị phân ($x_i \in \{0, 1\}$)

1. CÁC VẤN ĐỀ CỐT LÕI CỦA THUẬT TOÁN K LÁNG GIỀNG



■ Các hàm tính khoảng cách hình học (Geometry distance functions)

- Hàm Minkowski (p – norm):
$$d(x, z) = \left(\sum_{i=1}^n |x_i - z_i|^p \right)^{1/p}$$

- Hàm Manhattan ($p = 1$):
$$d(x, z) = \sum_{i=1}^n |x_i - z_i|$$

- Hàm Euclid ($p = 2$):
$$d(x, z) = \sqrt{\sum_{i=1}^n (x_i - z_i)^2}$$

- Hàm Chebyshev ($p = \infty$):
$$d(x, z) = \lim_{p \rightarrow \infty} \left(\sum_{i=1}^n |x_i - z_i|^p \right)^{1/p}$$
$$= \max_i |x_i - z_i|$$

1. CÁC VẤN ĐỀ CỐT LỖI CỦA THUẬT TOÁN K LÁNG GIỀNG



- Hàm khoảng cách Hamming
 - Đối với các thuộc tính đầu vào là kiểu nhị phân

$$d(x, z) = \sum_{i=1}^n \text{Difference}(x_i, z_i)$$

$$\text{Difference}(a, b) = \begin{cases} 1, & \text{if } (a \neq b) \\ 0, & \text{if } (a = b) \end{cases}$$

1. CÁC VẤN ĐỀ CỐT LÕI CỦA THUẬT TOÁN K LÁNG GIỀNG



- Chuẩn hóa miền giá trị thuộc tính
- Hàm tính khoảng cách Euclid:
$$d(x, z) = \sqrt{\sum_{i=1}^n (x_i - z_i)^2}$$
- Giả sử mỗi ví dụ được biểu diễn bởi 3 thuộc tính: Age, Income (cho mỗi tháng), và Height (đo theo mét)
 - $x = (\text{Age}=20, \text{Income}=12000, \text{Height}=1.68)$
 - $z = (\text{Age}=40, \text{Income}=1300, \text{Height}=1.75)$
- Khoảng cách giữa x và z
 - $d(x, z) = [(20 - 40)^2 + (12000 - 1300)^2 + (1.68 - 1.75)^2]^{0.5}$
 - Giá trị khoảng cách bị quyết định chủ yếu bởi giá trị khoảng cách (sự khác biệt) giữa 2 ví dụ đối với thuộc tính Income
 - Vì: Thuộc tính Income có miền giá trị rất lớn so với các thuộc tính khác
- Có thể chuẩn hóa miền giá trị (đưa về cùng một khoảng giá trị)
 - Khoảng giá trị $[0,1]$ thường được sử dụng
 - Đối với mỗi thuộc tính i : $x_i := x_i / \max(x_j)$

1. CÁC VẤN ĐỀ CỐT LỖI CỦA THUẬT TOÁN K LÁNG GIỀNG



- Chọn tập láng giềng $NB(z)$
 - Chọn bao nhiêu láng giềng?
 - Giới hạn chọn theo vùng?
- Trong thực tiễn ta nên lấy nhiều hàng xóm ($k > 1$) khi cần phân lớp/dự đoán, nhưng không quá nhiều. Lý do:
 - Tránh ảnh hưởng của lỗi/nhiều nếu chỉ dùng 1 hàng xóm.
 - Nếu quá nhiều hàng xóm thì sẽ phá vỡ cấu trúc tiềm ẩn trong dữ liệu.

1. CÁC VẤN ĐỀ CỐT LÕI CỦA THUẬT TOÁN K LÁNG GIỀNG



- Trọng số láng giềng
- Xét tập $NB(z)$ – gồm k ví dụ học gần nhất với ví dụ cần phân lớp/dự đoán z
 - Mỗi ví dụ (láng giềng gần nhất) này có khoảng cách khác nhau đến z
 - Các láng giềng này có ảnh hưởng như nhau đối với việc phân lớp/dự đoán cho z ? → KHÔNG!
- Có thể gán các mức độ ảnh hưởng (đóng góp) của mỗi láng giềng gần nhất tùy theo khoảng cách của nó đến z
 - Mức độ ảnh hưởng cao hơn cho các láng giềng gần hơn!

1. CÁC VẤN ĐỀ CỐT LÕI CỦA THUẬT TOÁN K LÁNG GIỀNG



- Gọi v là hàm xác định trọng số theo khoảng cách
 - Đối với một giá trị $d(x, z)$ – khoảng cách giữa x và z
 - $v(x, z)$ tỷ lệ nghịch với $d(x, z)$
- Đối với bài toán phân lớp: $c(z) = \arg \max_{c_j \in C} \sum_{x \in NB(z)} v(x, z) \cdot \text{Identical}(c_j, c(x))$

$$\text{Identical}(a, b) = \begin{cases} 1, & \text{if } (a = b) \\ 0, & \text{if } (a \neq b) \end{cases}$$

- Đối với bài toán dự đoán (hồi quy):

$$f(z) = \frac{\sum_{x \in NB(z)} v(x, z) \cdot f(x)}{\sum_{x \in NB(z)} v(x, z)}$$

- Lựa chọn một hàm xác định trọng số theo khoảng cách:

$$v(x, z) = \frac{1}{\alpha + d(x, z)} \quad v(x, z) = \frac{1}{\alpha + [d(x, z)]^2} \quad v(x, z) = e^{-\frac{d(x, z)^2}{\sigma^2}}$$

Bài học đã cung cấp cho người học các vấn đề cốt lõi của **thuật toán K láng giềng gần**: **Khoảng cách, số láng giềng gần, trọng số láng giềng**

NHẬP MÔN TRÍ TUỆ NHÂN TẠO


Một số vấn đề cốt lõi với K-láng giềng gần

Biên soạn:

TS. Ngô Văn Linh

Trình bày:

TS. Ngô Văn Linh



NHẬP MÔN TRÍ TUỆ NHÂN TẠO

Bài học tiếp theo:

Nhắc lại về xác suất

Tài liệu tham khảo:

- [1] T. M. Mitchell. *Machine Learning*. McGraw-Hill, 1997.
- [2] A. Kontorovich and Weiss. A Bayes consistent 1-NN classifier. Proceedings of the 18th International Conference on Artificial Intelligence and Statistics (AISTATS). JMLR: W&CP volume 38, 2015.
- [3] A. Guyader, N. Hengartner. On the Mutual Nearest Neighbors Estimate in Regression. *Journal of Machine Learning Research* 14 (2013) 2361-2376.
- [4] L. Gottlieb, A. Kontorovich, and P. Nisnevitch. Near-optimal sample compression for nearest neighbors. *Advances in Neural Information Processing Systems*, 2014.