




**ĐẠI HỌC BÁCH KHOA HÀ NỘI**  
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

*Nhóm chuyên môn Trí tuệ nhân tạo*

# NHẬP MÔN TRÍ TUỆ NHÂN TẠO

**Phân loại văn bản với Naive Bayes**



## Phân loại văn bản với Naïve Bayes

# MỤC TIÊU

---



*Sau bài học này, người học có thể:*

Ôn tập về Naïve Bayes, các vấn đề trong Naïve Bayes, nắm được phân loại văn bản với thuật toán Naïve Bayes.

## 1. Phân loại văn bản với Naïve Bayes

# 1. PHÂN LOẠI VĂN BẢN VỚI NAÏVE BAYES

---



- **Nhắc lại:** Biểu diễn bài toán phân loại (classification problem)
  - Một tập học  $D_{\text{train}}$ , trong đó mỗi ví dụ học  $x$  được biểu diễn là một vector  $n$  chiều:  $(x_1, x_2, \dots, x_n)$
  - Một tập xác định các nhãn lớp:  $C = \{c_1, c_2, \dots, c_m\}$
  - Với một ví dụ (mới)  $z$ , thì  $z$  sẽ được phân vào lớp nào?
- Mục tiêu: Xác định phân lớp có thể (phù hợp) nhất đối với  $z$

$$c_{MAP} = \arg \max_{c_i \in C} P(c_i | z)$$

$$c_{MAP} = \arg \max_{c_i \in C} P(c_i | z_1, z_2, \dots, z_n)$$

$$c_{MAP} = \arg \max_{c_i \in C} \frac{P(z_1, z_2, \dots, z_n | c_i) \cdot P(c_i)}{P(z_1, z_2, \dots, z_n)}$$

# 1. PHÂN LOẠI VĂN BẢN VỚI NAÏVE BAYES



- Để tìm được phân lớp có thể nhất đối với  $z$

$$C_{MAP} = \arg \max_{c_i \in C} P(z_1, z_2, \dots, z_n \mid c_i) \cdot P(c_i) \quad (P(z_1, z_2, \dots, z_n) \text{ là như nhau với các lớp})$$

- **Giả thuyết (assumption) trong phương pháp phân loại Naïve Bayes:** Các thuộc tính là *độc lập có điều kiện (conditionally independent)* đối với các lớp

$$P(z_1, z_2, \dots, z_n \mid c_i) = \prod_{j=1}^n P(z_j \mid c_i)$$

- Phân loại Naïve Bayes tìm phân lớp có thể nhất đối với  $z$

$$C_{NB} = \arg \max_{c_i \in C} P(c_i) \cdot \prod_{j=1}^n P(z_j \mid c_i)$$

# 1. PHÂN LOẠI VĂN BẢN VỚI NAÏVE BAYES

---



- Giai đoạn học (training phase), sử dụng một tập học
  - Đối với mỗi phân lớp có thể (mỗi nhãn lớp)  $c_i \in C$
  - Tính giá trị xác suất tiên nghiệm:  $P(c_i)$
  - Đối với mỗi giá trị thuộc tính  $x_j$ , tính giá trị xác suất xảy ra của giá trị thuộc tính đó đối với một phân lớp  $c_i$ :  $P(x_j | c_i)$
- Giai đoạn phân lớp (classification phase), đối với một ví dụ mới
  - Đối với mỗi phân lớp  $c_i \in C$ , tính giá trị của biểu thức:

$$P(c_i) \cdot \prod_{j=1}^n P(x_j | c_i)$$

- Xác định phân lớp của  $z$  là lớp có thể nhất  $c^*$

$$c^* = \arg \max_{c_i \in C} P(c_i) \cdot \prod_{j=1}^n P(x_j | c_i)$$

# 1. PHÂN LOẠI VĂN BẢN VỚI NAÏVE BAYES



- Vấn đề với Naïve Bayes
- Nếu không có ví dụ nào gắn với phân lớp  $c_i$  có giá trị thuộc tính  $x_j$ ...

$P(x_j|c_i)=0$  , và vì vậy:

$$P(c_i) \cdot \prod_{j=1}^n P(x_j | c_i) = 0$$

- Giải pháp: Sử dụng phương pháp Bayes để ước lượng  $P(x_j|c_i)$

$$P(x_j | c_i) = \frac{n(c_i, x_j) + mp}{n(c_i) + m}$$

- $n(c_i)$ : số lượng các ví dụ học gắn với phân lớp  $c_i$
- $n(c_i, x_j)$ : số lượng các ví dụ học gắn với phân lớp  $c_i$  có giá trị thuộc tính  $x_j$
- $p$ : ước lượng đối với giá trị xác suất  $P(x_j|c_i)$

→ Các ước lượng đồng mức:  $p=1/k$ , nếu thuộc tính  $f_j$  có  $k$  giá trị

- $m$ : một hệ số (trọng số)

→ Để bổ sung cho  $n(c_i)$  các ví dụ thực sự được quan sát với thêm  $m$  mẫu ví dụ với ước lượng  $p$



# 1. PHÂN LOẠI VĂN BẢN VỚI NAÏVE BAYES

---

- Giới hạn về độ chính xác trong tính toán của máy tính
  - $P(x_j|c_i) < 1$ , đối với mọi giá trị thuộc tính  $x_j$  và phân lớp  $c_i$
  - Vì vậy, khi số lượng các giá trị thuộc tính là rất lớn, thì:

$$\lim_{n \rightarrow \infty} \left( \prod_{j=1}^n P(x_j | c_i) \right) = 0$$

- Giải pháp: Sử dụng hàm lôgarit cho các giá trị xác suất

$$c_{NB} = \arg \max_{c_i \in C} \left( \log \left[ P(c_i) \cdot \prod_{j=1}^n P(x_j | c_i) \right] \right)$$

$$c_{NB} = \arg \max_{c_i \in C} \left( \log P(c_i) + \sum_{j=1}^n \log P(x_j | c_i) \right)$$

# 1. PHÂN LOẠI VĂN BẢN VỚI NAÏVE BAYES



- Biểu diễn bài toán phân loại văn bản
  - Tập học  $D$ , trong đó mỗi ví dụ học là một biểu diễn văn bản gắn với một nhãn lớp:  $D = \{(d_k, c_i)\}$
  - Một tập các nhãn lớp xác định:  $C = \{c_i\}$
- Giai đoạn học
  - Từ tập các văn bản trong  $D$ , trích ra tập các từ khóa  $T = \{t_j\}$
  - Gọi  $D_{c_i}$  là tập các văn bản trong  $D$  có nhãn lớp  $c_i$
  - Đối với mỗi phân lớp  $c_i$ 
    - Tính giá trị xác suất trước của phân lớp  $c_i$ :  $P(c_i) = \frac{|D_{c_i}|}{|D|}$
    - Đối với mỗi từ khóa  $t_j$ , tính xác suất từ khóa  $t_j$  xuất hiện đối với lớp  $c_i$

$$P(t_j | c_i) = \frac{\left( \sum_{d_k \in D_{c_i}} n(d_k, t_j) \right) + 1}{\left( \sum_{d_k \in D_{c_i}} \sum_{t_m \in T} n(d_k, t_m) \right) + |T|}$$

$(n(d_k, t_j))$  : số lần xuất hiện của từ khóa  $t_j$  trong văn bản  $d_k$

# 1. PHÂN LOẠI VĂN BẢN VỚI NAÏVE BAYES



- Giai đoạn phân lớp đối với một văn bản mới  $d$ 
  - Từ văn bản  $d$ , trích ra tập  $T_d$  gồm các từ khóa (keywords)  $t_j$  đã được định nghĩa trong tập  $T$
  - **Giả sử (assumption).** Xác suất từ khóa  $t_j$  xuất hiện đối với lớp  $c_i$  là độc lập đối với vị trí của từ khóa đó trong văn bản

$$P(t_j \text{ ở vị trí } k | c_i) = P(t_j \text{ ở vị trí } m | c_i), \forall k, m$$

- Đối với mỗi phân lớp  $c_i$ , tính xác suất hậu nghiệm của văn bản  $d$  đối với  $c_i$

$$P(c_i) \cdot \prod_{t_j \in T_d} P(t_j | c_i)$$

- Phân lớp văn bản  $d$  thuộc vào lớp  $c^*$

$$c^* = \arg \max_{c_i \in C} P(c_i) \cdot \prod_{t_j \in T_d} P(t_j | c_i)$$

Bài học ôn tập về Naïve Bayes, các vấn đề trong Naïve Bayes và ứng dụng Naïve Bayes trong phân loại văn bản.

# NHẬP MÔN TRÍ TUỆ NHÂN TẠO


## Phân loại văn bản với Naive Bayes

Biên soạn:

TS. Ngô Văn Linh

Trình bày:

TS. Ngô Văn Linh



# NHẬP MÔN TRÍ TUỆ NHÂN TẠO

*Bài học tiếp theo:*

**Học máy không giám sát trong đầu tư các công ty**

**Tài liệu tham khảo:**

- [1] T. M. Mitchell. *Machine Learning*. McGraw-Hill, 1997.
- [2] A. Kontorovich and Weiss. A Bayes consistent 1-NN classifier. Proceedings of the 18th International Conference on Artificial Intelligence and Statistics (AISTATS). JMLR: W&CP volume 38, 2015.
- [3] A. Guyader, N. Hengartner. On the Mutual Nearest Neighbors Estimate in Regression. *Journal of Machine Learning Research* 14 (2013) 2361-2376.
- [4] L. Gottlieb, A. Kontorovich, and P. Nisnevitch. Near-optimal sample compression for nearest neighbors. *Advances in Neural Information Processing Systems*, 2014.